INTRODUCTION

PARADETOX

Peut-on supprimer la toxicité sans modifier le sens ?

Génération de paraphrases non toxiques avec des architectures Encoder-Decoder entraînées depuis zéro.

ROMDHANI Soumaya

Master 2 Intelligence Artificielle & Data Science

Université Paris Dauphine-PSL · 2026-2027

01 · TÂCHE CHOISIE

LA DÉTOXIFICATION : UNE TÂCHE DE GÉNÉRATION, PAS DE CLASSIFICATION

Transformer une phrase potentiellement offensante en une paraphrase neutre, tout en conservant le sens, les faits et la correction grammaticale (Paraphrase).

PHRASE SOURCE

“Your idea is stupid.”

SORTIE RÉELLEMENT GÉNÉRÉE

“Your idea is bad.”

Réduire la toxicité

Préserver le sens

Produire une phrase correcte

Type de tâche NLP : Paraphrase Generation, formulée comme un apprentissage supervisé Sequence-to-Sequence.

02 · LE CORPUS

PARADETOX : APPRENDRE À PARTIR DE PAIRES TOXIQUE → NEUTRE

Phrases anglaises toxiques associées à leurs reformulations neutres (Hugging Face, s-nlp/paradetox).

19 744

Paires initiales

19 003

Paires conservées

741

Paires retirées

Test : 1 901 paires, correspondant à 1 193 phrases sources distinctes. Le découpage regroupe les doublons textuels pour limiter les fuites entre partitions.

Entraînement : 16 823 exemples effectifs après augmentation (voir prétraitement).

02 · PRÉTRAITEMENT

TRANSFORMER LES PHRASES EN REPRÉSENTATIONS NUMÉRIQUES

Texte brut

Nettoyage et normalisation Unicode

SentencePiece BPE — 2 000 sous-mots

Token IDs + tokens spéciaux

Embeddings entraînables de dimension 96

- Tokens spéciaux : PAD, UNK, BOS, EOS.
- Tokenizer appris à partir du corpus d'entraînement ; PAD est ignoré dans la fonction de perte.
- Augmentation limitée au train : 1 216 paires neutre → neutre et 406 rééchantillonnages ciblés, soit 16 823 exemples d'entraînement effectifs.

03 · ARCHITECTURE

COMMENT FONCTIONNE NOTRE ENCODER–DECODER ?

L’encodeur lit la phrase source et produit des états cachés ; le décodeur génère la paraphrase un token à la fois.

Encodeur BiLSTM

Représentations bidirectionnelles du contexte à partir de la phrase source tokenisée.

Décodeur LSTM

Prédiction du prochain token à chaque étape, à partir des représentations de l’encodeur.

Paraphrase générée

Génération jusqu’au token EOS.

$$P(y \mid x) = \prod_{t=1}^{m} P(y_t \mid y_{<t}, x)$$

Le modèle apprend à maximiser la probabilité de la séquence cible conditionnellement à la phrase d’entrée.

03 · COMPARAISON

TROIS ARCHITECTURES POUR COMPRENDRE LE RÔLE DE L'ATTENTION ET DE LA COPIE

Architecture	Paramètres	Principe
01 · BiLSTM Encoder–Decoder (baseline)	949 712	Le décodeur utilise surtout les derniers états de l'encodeur ; cette représentation fixe peut perdre des détails.
02 · BiLSTM + Attention	1 370 576	À chaque étape, le décodeur pondère les états de l'encodeur pour sélectionner les informations pertinentes.
03 · BiLSTM + Attention + Pointer	1 371 057	Combine génération et copie des tokens source ; conserve mieux certaines informations, mais peut recopier des expressions toxiques.

Les trois architectures sont implémentées et entraînées depuis zéro avec PyTorch, sans fine-tuning d'un modèle génératif

04 · ENTRAÎNEMENT

COMMENT LES MODÈLES ONT-ILS ÉTÉ ENTRAÎNÉS ?

Réglage	Valeur
Optimiseur	AdamW
Learning rate	0,002
Batch size	64
Hidden size	192
Époques initiales	14 max.
Dropout	0,25
Graine	42

Apprentissage

- Fonction de perte : NLL par token, hors padding
- Teacher forcing initial à 100 %
- Gradient clipping à 1,0
- Scheduler ReduceLROnPlateau
- Early stopping sur la validation
- Meilleur checkpoint : NLL de validation minimale

Pourquoi le teacher forcing ?

Pendant l'entraînement, le décodeur reçoit le vrai token précédent. À l'inférence, il doit utiliser ses propres prédictions.

Expérience complémentaire : Attention prolongée jusqu'à 25 époques max., avec scheduled sampling expérimental.

COMMENT LE MODÈLE CHOISIT-IL LA MEILLEURE REFORMULATION ?

Greedy Decoding

Sélectionne le token le plus probable à chaque étape. Simple et rapide, mais les décisions locales peuvent être sous-optimales.

Beam Search

Conserve plusieurs séquences candidates et compare leurs probabilités cumulées avec une normalisation de longueur.

Safe Decoding

Reclasse les candidats selon leur vraisemblance, leur complétude et des contrôles de conservation des informations.

Évaluation multi-critères

BLEU / chrF pour le recouvrement avec les références ; classifieur pour la toxicité ; similarité cosinus pour la proximité sémantique ; diagnostics de répétition et de préservation des informations.

Le système final a été choisi sur la validation, avant l'évaluation finale sur le test.

06 · RÉSULTATS

L'ATTENTION AMÉLIORE FORTEMENT LES PERFORMANCES DE GÉNÉRATION

66,59

BLEU final

79,88

chrF final

66,81 %

Proxy conjoint

Interprétation

- La baseline produit un texte souvent peu toxique, mais perd fortement le contenu.
- L'attention apporte un gain majeur en fidélité.
- Pointer + Safe Decoding obtient le meilleur compromis mesuré parmi les candidats évalués.

Test : 1 193 sources distinctes. Le proxy conjoint est un indicateur automatique, pas un taux de phrases parfaitement correctes selon une évaluation humaine.

QUAND LE MODÈLE PARVIENT À REFORMULER CORRECTEMENT

Exemples sélectionnés parmi les sorties effectivement générées.

Entrée	Sortie générée
“Your idea is stupid.”	“Your idea is bad.”
“This damn computer keeps crashing.”	“This computer keeps crashing.”
“What the hell are you doing?”	“What are you doing?”

Les expressions offensantes explicites peuvent souvent être supprimées ou remplacées tout en conservant la structure de la phrase.

07 · LIMITES OBSERVÉES

RÉDUIRE LA TOXICITÉ NE GARANTIT PAS UNE PHRASE CORRECTE

Entrée	Sortie observée	Erreur
“Stop acting like an idiot.”	“Stop acting like an.”	Phrase incomplète après suppression de l’insulte.
“What a dumb decision!”	“What an decision!”	Choix grammatical incorrect de l’article.
“She worked her ass off to prepare the presentation.”	“She worked her off to prepare the presentation.”	Expression idiomatique fragmentée.

Ces cas montrent les limites des reformulations locales : certaines expressions doivent être réécrites comme un ensemble.

La détoxification n’est pas une simple suppression de mots. Le véritable défi est de préserver le message tout en améliorant sa formulation.

Merci pour votre attention.